Nombre

Eithan Samir

Apellido

Pérez Valera

Matricula

2025-1211

Carrera

Desarrollo de Software

Materia

Electiva 1

Nombre del docente

Francis Ramírez

Tema

Carga de la base de datos trasaccional

1. Introducción

En la etapa anterior diseñé la base de datos transaccional del sistema, con sus tablas, claves primarias y foráneas. En esta entrega la lleno con datos reales. Para eso desarrollé en Python un proceso ETL que toma seis archivos CSV, los revisa, los limpia y los inserta en SQL Server sin romper ninguna relación entre tablas.

El proceso no inserta todo a ciegas. Cada registro se valida. Los que no cumplen las reglas se apartan junto con el motivo, y al final se muestra cuántos registros se procesaron, cuántos se insertaron y cuántos se rechazaron.

2. Herramientas utilizadas

- SQL Server y SSMS, para la base de datos y las consultas.
- Python 3 [versión], para el proceso ETL.
- pyodbc con ODBC Driver 17, para conectar Python con SQL Server.
- unittest, para 16 pruebas automáticas de la lógica.
- Servidor: LAPTOP-PICKUR9K (Mi laptop). Base de datos: AnalisisOpinionesTransaccional. Autenticación de Windows.
- unittest, para 30 pruebas automáticas de las validaciones.

3. Cómo está pensada la solución

Trabajé con dos capas, para no mezclar “leer el archivo” con “decidir qué se acepta”:

```
CSV  ──►  Capa 1: Staging (stg)  ──►  Capa 2: Transaccional (dbo)
          copia cruda, en texto        datos validados y relacionados
          + archivo y fila de origen   + rechazos con su motivo
```

La capa 1 solo comprueba que el archivo sea utilizable (que exista, que no esté vacío, que tenga las columnas esperadas) y lo copia tal cual. La capa 2 hace el trabajo de fondo: limpia, valida, busca duplicados, verifica las relaciones e inserta. Lo que no pasa se guarda en stg.RegistrosRechazados, así que nada se pierde sin explicación.

El código está separado por responsabilidades:

- main.py: punto de entrada. Coordina las dos capas, maneja los errores y escribe el registro de la ejecución.
- etl/extract.py: lee los CSV y los carga a staging.
- etl/transform.py: funciones de limpieza y normalización.

- etl/validate.py: reglas de validación de cada entidad.
- etl/load.py: carga a las tablas finales, detección de duplicados y de integridad.
- etl/resumen.py: verificación final e impresión del resumen.
- etl/database.py: conexión y transacciones.
- etl/modelos.py: excepciones propias y contadores.
- etl/modo_prueba.py: base de datos SQLite en memoria que usan las pruebas, para no tocar SQL Server.
- tests/test_etl.py: pruebas automáticas de las validaciones del ETL.

4. Base de datos

El script sql/script_base_datos.sql crea todo desde cero y se puede ejecutar varias veces. Contiene:

- Las 6 tablas transaccionales (esquema dbo): Clientes, Productos, FuenteDatos, Encuestas, ResenasWeb y ComentariosSociales, con PK, FK, UNIQUE, CHECK e índices.
- Las tablas de staging (esquema stg): una por cada CSV, más RegistrosRechazados.
- 4 vistas: vw_OpinionesUnificadas, vw_SatisfaccionPorProducto, vw_TendenciaSatisfaccionMensual y vw_ResumenRechazos.
- 4 procedimientos almacenados: usp_OpinionesPorProducto, usp_SatisfaccionPorProducto, usp_ResumenCarga y usp_ReiniciarCarga.

Las tres tablas de opiniones dependen de Productos y FuenteDatos. También dependen de Clientes, que es obligatorio en Encuestas y opcional en reseñas web y comentarios sociales.

5. Recorrido del proceso

Extracción.

Se leen los seis archivos y se comprueba su estructura. El proceso detecta la codificación (UTF-8 o ANSI) y el separador (coma o punto y coma). Si falta un archivo, está vacío o le faltan columnas, se informa con un mensaje claro.

Transformación.

Se limpian los textos y se normalizan los datos para que sean comparables:

- Los IDs con prefijo pasan a número (“C007” y “7” dan 7).
- Los correos se guardan en minúscula.

- Las fechas de distintos formatos se convierten a una sola (no pueden ser futuras ni anteriores a 1990).
- El tipo de fuente y la plataforma se llevan a los valores permitidos.
- Puntaje y rating deben estar entre 1 y 5.

Validación.

Se rechaza el registro si cumple alguno de estos casos:

- Faltan campos obligatorios.
- El formato o el tipo de dato es incorrecto.
- El valor está fuera de rango o de catálogo.
- El texto supera la longitud máxima.
- Es un duplicado, ya sea por ID, correo, código de fuente o contenido repetido.
- Referencia un cliente, producto o fuente que no existe.

Carga.

Respeta el orden de las dependencias: primero clientes, productos y fuentes, y después encuestas, reseñas y comentarios. Si la capa 2 falla, se hace rollback y la base no queda a medias. Cada ejecución limpia las dos capas y recarga, por eso repetirla no duplica datos.

Resumen.

Al terminar se muestra una tabla con procesados, staging, insertados y rechazados por entidad, los motivos de rechazo, una verificación contra la base (conteos y registros huérfanos) y el tiempo total.

6. Relación con lo que pide el enunciado

- Leer los datos de una fuente: se leen los 6 CSV (etl/extract.py).
- Validar estructura: archivo, encabezados y número de columnas (etl/extract.py).
- Limpiar y transformar: etl/transform.py.
- Detectar duplicados: etl/load.py y restricciones UNIQUE.
- Insertar respetando PK y FK: etl/load.py y el script SQL.
- Mostrar procesados, insertados y rechazados, y un resumen final: etl/resumen.py.
- Manejar errores con excepciones: etl/modelos.py y main.py.

7. Resultados de la ejecución

Entidad	Procesados	Insertados	Rechazados
Clientes	500	500	0
Productos	200	200	0
FuenteDatos	100	100	0
Encuestas	500	6	494
ResenasWeb	200	200	0
ComentariosSociales	200	200	0
Total	**1700**	**1206**	**494**

La ejecución duró 2.5 segundos y la verificación final no encontró registros huérfanos. Si se ejecuta el proceso otra vez, el resultado es el mismo, porque siempre parte de cero.

8. Hallazgos sobre la calidad de los datos

- **Encuestas con referencias inexistentes.** El archivo de encuestas menciona clientes de hasta el 9983 y productos de hasta el 997, pero los catálogos solo llegan al cliente 500 y al producto 200. Por eso 494 de las 500 encuestas se rechazan: 386 por cliente y producto inexistentes, 87 por cliente inexistente y 21 por producto inexistente. Preferí rechazarlas con su motivo antes que inventar clientes o productos para forzar la carga.
- **Comentarios anónimos.** 88 de los 200 comentarios sociales no traen cliente. Se cargan con el cliente en NULL, porque el modelo lo permite en ese canal.
- **Fuente de cada opinión.** Los archivos de opiniones no indican su fuente. Asumí que cada opinión viene de la fuente del tipo de su canal (encuestas: CSV, reseñas: Web, comentarios: Red Social), eligiendo la de fecha de carga más cercana a la fecha de la opinión.
- **Clasificación de encuestas.** Se guarda en staging pero no en la tabla final, porque el modelo no tiene ese campo y se puede derivar del puntaje.

9. Consultas de validación

Preparé 10 consultas en sql/consultas_validacion.sql (el enunciado pide al menos 5):

1. Conteo de registros por tabla. Esperado: 500, 200, 100, 6, 200 y 200.

2. Registros huérfanos, con 9 comprobaciones de FK. Esperado: todas en 0.
3. Duplicados de IDs, correos, códigos y opiniones, con 5 comprobaciones. Esperado: todas en 0.
4. Cuadre entre staging, cargados y rechazados. Esperado: “SI” en las 6 entidades.
5. Resumen de rechazos por motivo. Esperado: 494 en total.
6. Cada opinión usa una fuente del tipo de su canal. Esperado: 0 inconsistencias.
7. Puntajes y ratings dentro del rango 1 a 5. Esperado: 0 fuera de rango.
8. JOIN de reseñas con cliente, producto y fuente. Esperado: 10 filas con datos integrados.
9. Intento de insertar una opinión con un cliente inexistente (con ROLLBACK). Esperado: error 547 de clave foránea.
10. Vistas y procedimientos almacenados. Esperado: datos de satisfacción y opiniones por producto.

Los NULL que aparecen en la consulta 10 son normales: hay comentarios anónimos y no todas las opiniones tienen todos los campos.

10. Pruebas automáticas de validación

Además de las consultas SQL, creé 30 pruebas automáticas con la librería unittest de Python (archivo tests/test_etl.py). Su objetivo es comprobar que las validaciones del ETL rechazan los datos incorrectos y aceptan los correctos, sin depender de que SQL Server esté encendido. Usan una base SQLite en memoria que replica las dos capas con las mismas claves primarias, foráneas y restricciones.

Las pruebas cubren estos grupos:

- Transformaciones: IDs con prefijo (“C007” y “7” dan 7), correos en minúscula, fechas en varios formatos, fechas futuras o inválidas, puntajes fuera del rango 1 a 5, y catálogos de fuente y plataforma.
- Carga con datos sucios a propósito: duplicados por ID, correo, código y contenido; formatos incorrectos; campos obligatorios vacíos; y clientes o productos inexistentes. Cada error debe rechazarse con su motivo y quedar registrado.
- Estructura de los archivos: archivo faltante, archivo vacío, columna faltante en el encabezado y filas con columnas de más.
- Consistencia: procesados igual a insertados más rechazados, ningún registro huérfano, y repetir el ETL sin duplicar datos.
- Restricciones de la base: la clave foránea, el CHECK y el UNIQUE impiden datos inválidos aunque el ETL falle.

- Datos reales: con los 6 CSV del proyecto el resultado es 1,206 insertados y 494 rechazados.

Resultado: las 30 pruebas pasan (OK).

Cómo ejecutar las pruebas automáticas

Las pruebas no necesitan SQL Server, porque usan una base de datos en memoria. Para ejecutarlas:

- Abrir una terminal (CMD, PowerShell o la terminal de Visual Studio Code) dentro de la carpeta principal del proyecto, la misma donde está main.py.
- Verificar que Python esté instalado escribiendo python --version. Si da error, instalar Python primero. Las pruebas no requieren instalar ninguna librería adicional.
- Ejecutar el siguiente comando:

python -m unittest discover -s tests -v

11. Evidencias

1. Ejecución del proceso de carga.

```
PS C:\Users\eitha\Downloads\ETL_Opiniones\ETL_Opiniones> python main.py
22:25:09 [INFO] Proceso ETL iniciado. Registro en C:\Users\eitha\Downloads\ETL_Opiniones\ETL_Opiniones\logs\etl_20261022_222509.log
22:25:09 [INFO] Conectando a  / AnalisisOpinionesTransaccional con el driver 'ODBC Driver 17 for SQL Server'
22:25:09 [INFO] === CAPA 1: extracción de los CSV a staging ===
22:25:09 [INFO] [Capa 1] Clientes             500 leídos ->  500 en staging, 0 rechazados
22:25:09 [INFO] [Capa 1] Productos            200 leídos ->  200 en staging, 0 rechazados
22:25:09 [INFO] [Capa 1] FuenteDatos          100 leídos ->  100 en staging, 0 rechazados
22:25:10 [INFO] [Capa 1] Encuestas            500 leídos ->  500 en staging, 0 rechazados
22:25:10 [INFO] [Capa 1] ResenasWeb           200 leídos ->  200 en staging, 0 rechazados
22:25:10 [INFO] [Capa 1] ComentariosSociales   200 leídos ->  200 en staging, 0 rechazados
22:25:10 [INFO] === CAPA 2: validación y carga a la base transaccional ===
22:25:11 [INFO] [Capa 2] Clientes             500 insertados, 0 rechazados
22:25:11 [INFO] [Capa 2] Productos            200 insertados, 0 rechazados
22:25:11 [INFO] [Capa 2] FuenteDatos          100 insertados, 0 rechazados
22:25:11 [INFO] [Capa 2] Encuestas              6 insertados, 494 rechazados
22:25:11 [INFO] [Capa 2] ResenasWeb           200 insertados, 0 rechazados
22:25:11 [INFO] [Capa 2] ComentariosSociales   200 insertados, 0 rechazados

======================================================================
RESUMEN DEL PROCESO ETL
======================================================================
Inicio: 2026-10-22 22:25:09   Fin: 2026-10-22 22:25:11   Duración: 2.5 s

Entidad               Procesados   Staging  Insertados  Rechazados
----------------------------------------------------------------
Clientes                     500       500         500           0
Productos                    200       200         200           0
FuenteDatos                  100       100         100           0
Encuestas                    500       500           6         494
ResenasWeb                   200       200         200           0
ComentariosSociales          200       200         200           0
----------------------------------------------------------------
TOTAL                       1700      1700        1206         494

Motivos de rechazo:
  [Encuestas] Integridad referencial: el cliente y el producto no existen en los catálogos: 386
  [Encuestas] Integridad referencial: el cliente no existe en el catálogo de clientes: 87
  [Encuestas] Integridad referencial: el producto no existe en el catálogo de productos: 21

Verificación en la base de datos:
  Procesados = insertados + rechazados en todas las entidades: SÍ
  Los registros guardados en las 6 tablas coinciden con los insertados: SÍ
  Registros huérfanos (integridad referencial): 0 en 9 comprobaciones

RESULTADO: CARGA COMPLETADA CORRECTAMENTE
Hay 494 registros rechazados; el detalle está en la tabla stg.RegistrosRechazados.
======================================================================
PS C:\Users\eitha\Downloads\ETL_Opiniones\ETL_Opiniones>
```

2. Datos cargados correctamente en la base de datos de su preferencia.

```
-- ------------------------------------------------------------
-- CONSULTA 1: Cantidad de registros cargados en cada tabla
-- Esperado: Clientes 500, Productos 200, FuenteDatos 100,
--           Encuestas 6, ResenasWeb 200, ComentariosSociales 200
-- ------------------------------------------------------------
SELECT 'Clientes' AS Tabla, COUNT(*) AS Registros FROM dbo.Clientes
UNION ALL SELECT 'Productos', COUNT(*) FROM dbo.Productos
UNION ALL SELECT 'FuenteDatos', COUNT(*) FROM dbo.FuenteDatos
UNION ALL SELECT 'Encuestas', COUNT(*) FROM dbo.Encuestas
UNION ALL SELECT 'ResenasWeb', COUNT(*) FROM dbo.ResenasWeb
UNION ALL SELECT 'ComentariosSociales', COUNT(*) FROM dbo.ComentariosSociales;
GO
```

142 %

Results | Messages

	Tabla	Registros
1	Clientes	500
2	Productos	200
3	FuenteDatos	100
4	Encuestas	6
5	ResenasWeb	200
6	ComentariosSociales	200

3. Capturas de pantalla de las tablas pobladas.

Tabla clientes:

SQLQuery1.sql - LA...CKUR9K\eitha (64))* | 02_consultas_valid...ICKUR9K\eitha (51))

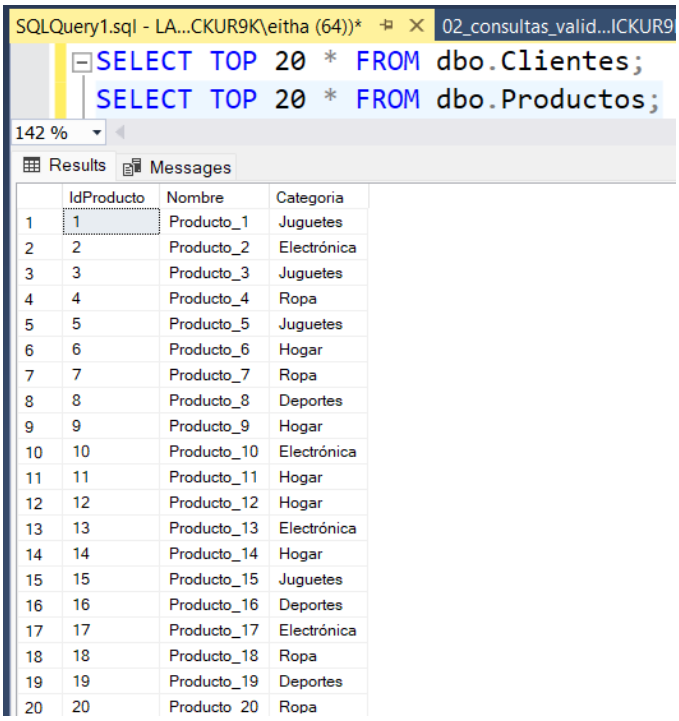
```
SELECT TOP 20 * FROM dbo.Clientes;
SELECT TOP 20 * FROM dbo.Productos;
SELECT TOP 20 * FROM dbo.FuenteDatos;
SELECT TOP 20 * FROM dbo.Encuestas;
SELECT TOP 20 * FROM dbo.ResenasWeb;
SELECT TOP 20 * FROM dbo.ComentariosSociales;
SELECT TOP 20 * FROM stg.RegistrosRechazados;
```

142 %

Results | Messages

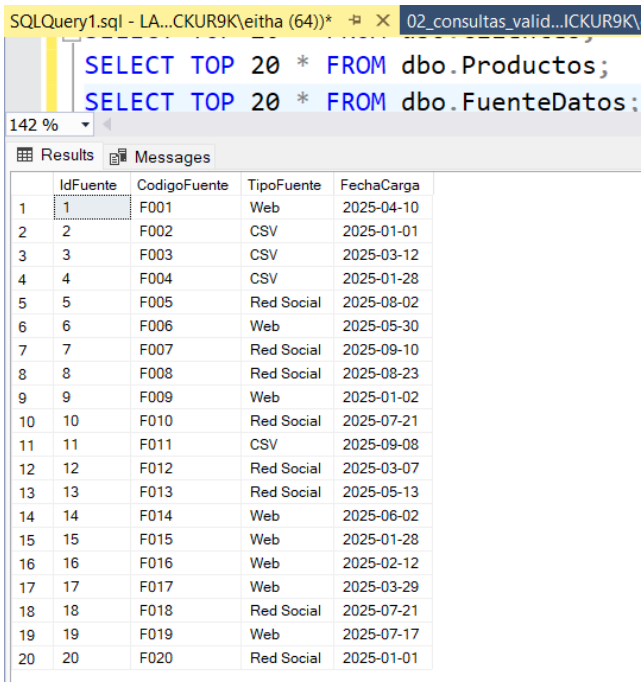
	IdCliente	Nombre	Email
1	1	Cliente_1	cliente1@mail.com
2	2	Cliente_2	cliente2@mail.com
3	3	Cliente_3	cliente3@mail.com
4	4	Cliente_4	cliente4@mail.com
5	5	Cliente_5	cliente5@mail.com
6	6	Cliente_6	cliente6@mail.com
7	7	Cliente_7	cliente7@mail.com
8	8	Cliente_8	cliente8@mail.com
9	9	Cliente_9	cliente9@mail.com
10	10	Cliente_10	cliente10@mail.com
11	11	Cliente_11	cliente11@mail.com
12	12	Cliente_12	cliente12@mail.com
13	13	Cliente_13	cliente13@mail.com
14	14	Cliente_14	cliente14@mail.com
15	15	Cliente_15	cliente15@mail.com
16	16	Cliente_16	cliente16@mail.com
17	17	Cliente_17	cliente17@mail.com

Tabla Productos:



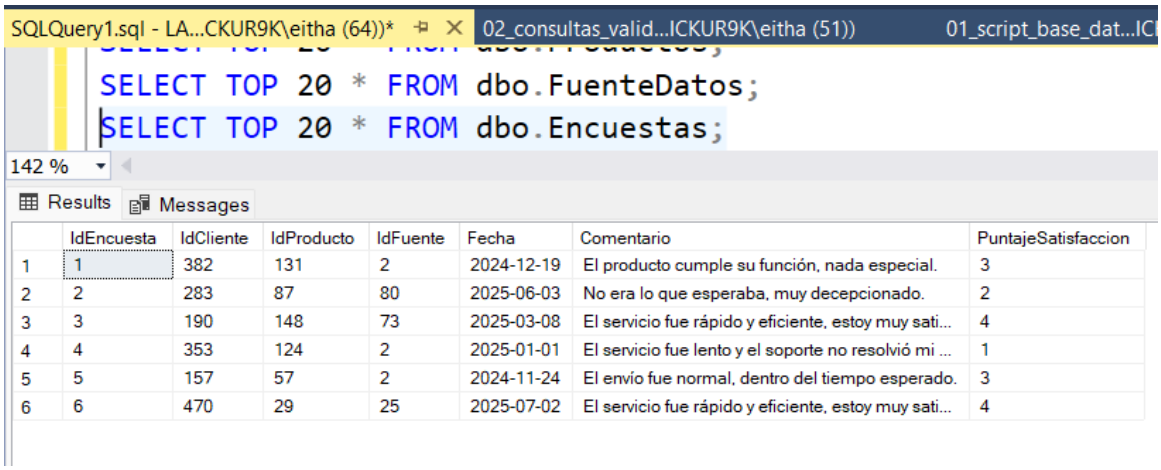
	IdProducto	Nombre	Categoria
1	1	Producto_1	Juguetes
2	2	Producto_2	Electrónica
3	3	Producto_3	Juguetes
4	4	Producto_4	Ropa
5	5	Producto_5	Juguetes
6	6	Producto_6	Hogar
7	7	Producto_7	Ropa
8	8	Producto_8	Deportes
9	9	Producto_9	Hogar
10	10	Producto_10	Electrónica
11	11	Producto_11	Hogar
12	12	Producto_12	Hogar
13	13	Producto_13	Electrónica
14	14	Producto_14	Hogar
15	15	Producto_15	Juguetes
16	16	Producto_16	Deportes
17	17	Producto_17	Electrónica
18	18	Producto_18	Ropa
19	19	Producto_19	Deportes
20	20	Producto_20	Ropa

Tabla fuentes de datos:



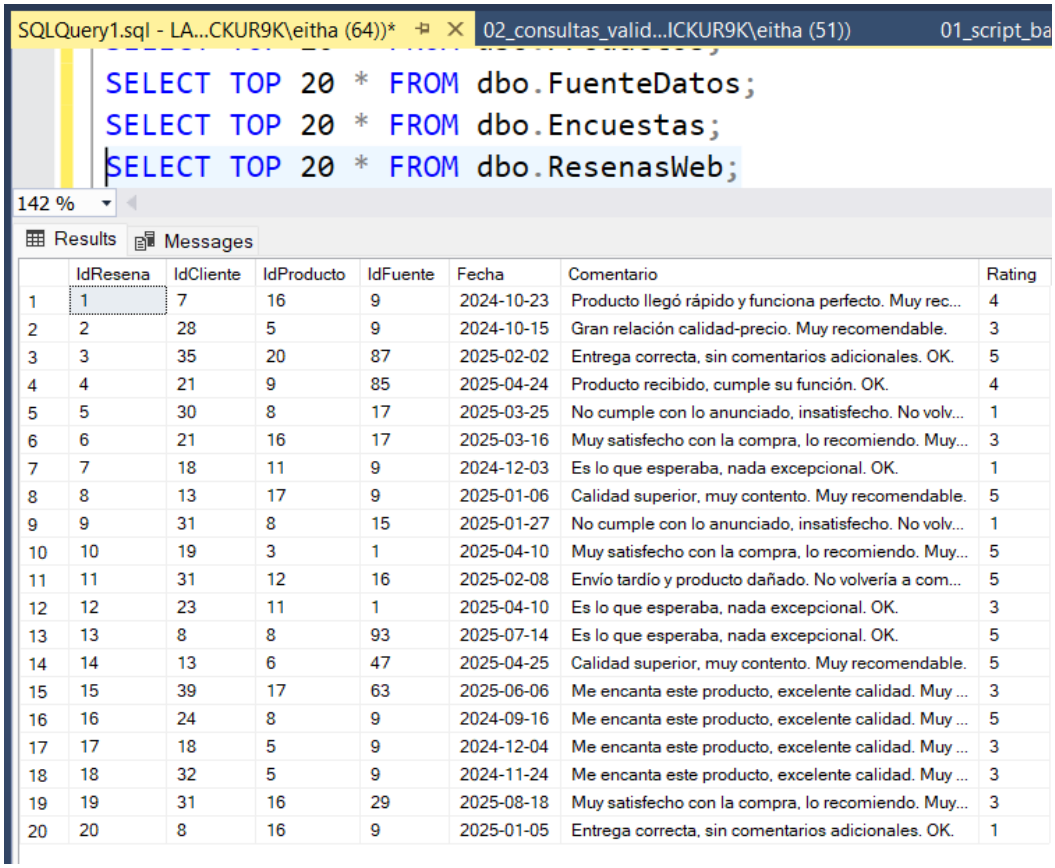
	IdFuente	CodigoFuente	TipoFuente	FechaCarga
1	1	F001	Web	2025-04-10
2	2	F002	CSV	2025-01-01
3	3	F003	CSV	2025-03-12
4	4	F004	CSV	2025-01-28
5	5	F005	Red Social	2025-08-02
6	6	F006	Web	2025-05-30
7	7	F007	Red Social	2025-09-10
8	8	F008	Red Social	2025-08-23
9	9	F009	Web	2025-01-02
10	10	F010	Red Social	2025-07-21
11	11	F011	CSV	2025-09-08
12	12	F012	Red Social	2025-03-07
13	13	F013	Red Social	2025-05-13
14	14	F014	Web	2025-06-02
15	15	F015	Web	2025-01-28
16	16	F016	Web	2025-02-12
17	17	F017	Web	2025-03-29
18	18	F018	Red Social	2025-07-21
19	19	F019	Web	2025-07-17
20	20	F020	Red Social	2025-01-01

Tabla Encuestas:



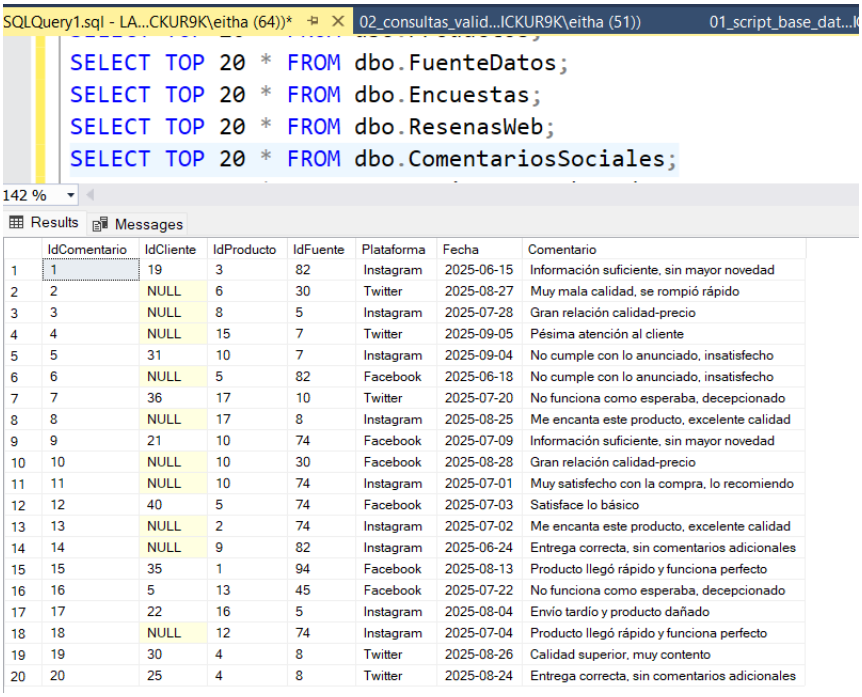
	IdEncuesta	IdCliente	IdProducto	IdFuente	Fecha	Comentario	PuntajeSatisfaccion
1	1	382	131	2	2024-12-19	El producto cumple su función, nada especial.	3
2	2	283	87	80	2025-06-03	No era lo que esperaba, muy decepcionado.	2
3	3	190	148	73	2025-03-08	El servicio fue rápido y eficiente, estoy muy sati...	4
4	4	353	124	2	2025-01-01	El servicio fue lento y el soporte no resolvió mi ...	1
5	5	157	57	2	2024-11-24	El envío fue normal, dentro del tiempo esperado.	3
6	6	470	29	25	2025-07-02	El servicio fue rápido y eficiente, estoy muy sati...	4

Tabla ResenasWeb:



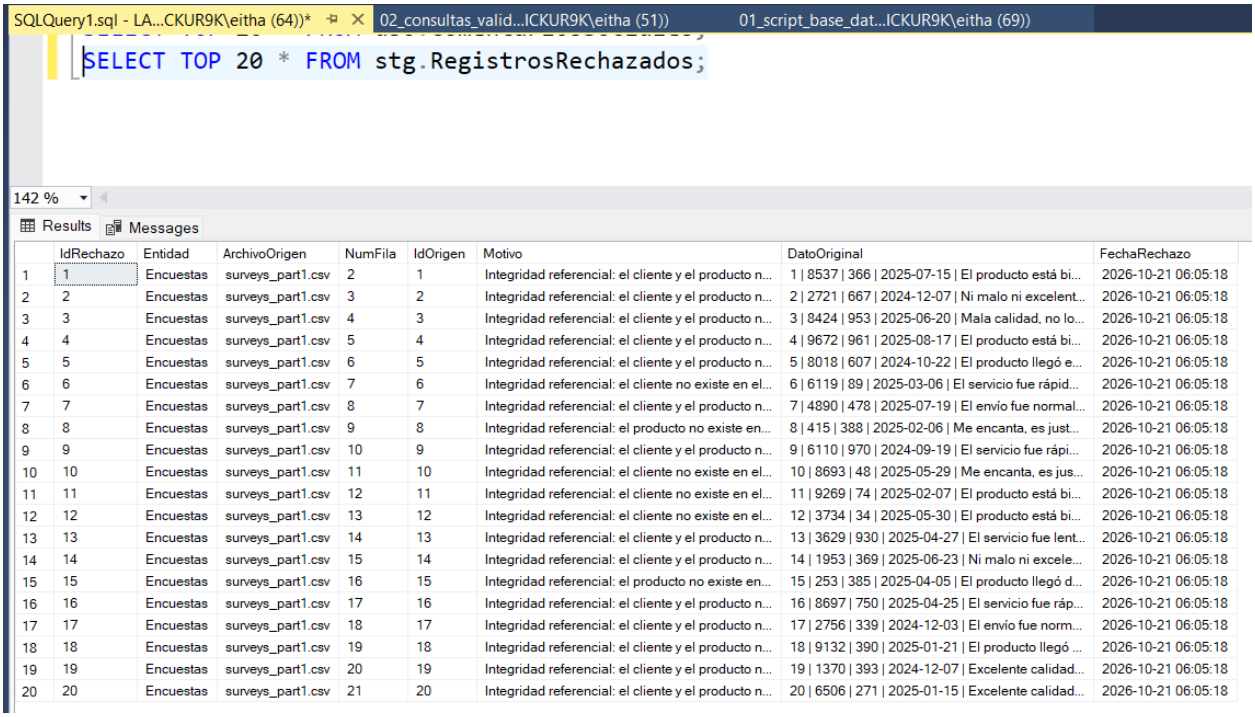
	IdResena	IdCliente	IdProducto	IdFuente	Fecha	Comentario	Rating
1	1	7	16	9	2024-10-23	Producto llegó rápido y funciona perfecto. Muy rec...	4
2	2	28	5	9	2024-10-15	Gran relación calidad-precio. Muy recomendable.	3
3	3	35	20	87	2025-02-02	Entrega correcta, sin comentarios adicionales. OK.	5
4	4	21	9	85	2025-04-24	Producto recibido, cumple su función. OK.	4
5	5	30	8	17	2025-03-25	No cumple con lo anunciado, insatisfecho. No volv...	1
6	6	21	16	17	2025-03-16	Muy satisfecho con la compra, lo recomiendo. Muy...	3
7	7	18	11	9	2024-12-03	Es lo que esperaba, nada excepcional. OK.	1
8	8	13	17	9	2025-01-06	Calidad superior, muy contento. Muy recomendable.	5
9	9	31	8	15	2025-01-27	No cumple con lo anunciado, insatisfecho. No volv...	1
10	10	19	3	1	2025-04-10	Muy satisfecho con la compra, lo recomiendo. Muy...	5
11	11	31	12	16	2025-02-08	Envío tardío y producto dañado. No volvería a com...	5
12	12	23	11	1	2025-04-10	Es lo que esperaba, nada excepcional. OK.	3
13	13	8	8	93	2025-07-14	Es lo que esperaba, nada excepcional. OK.	5
14	14	13	6	47	2025-04-25	Calidad superior, muy contento. Muy recomendable.	5
15	15	39	17	63	2025-06-06	Me encanta este producto, excelente calidad. Muy ...	3
16	16	24	8	9	2024-09-16	Me encanta este producto, excelente calidad. Muy ...	5
17	17	18	5	9	2024-12-04	Me encanta este producto, excelente calidad. Muy ...	3
18	18	32	5	9	2024-11-24	Me encanta este producto, excelente calidad. Muy ...	3
19	19	31	16	29	2025-08-18	Muy satisfecho con la compra, lo recomiendo. Muy...	3
20	20	8	16	9	2025-01-05	Entrega correcta, sin comentarios adicionales. OK.	1

Tabla ComentariosSociales:



	IdComentario	IdCliente	IdProducto	IdFuente	Plataforma	Fecha	Comentario
1	1	19	3	82	Instagram	2025-06-15	Información suficiente, sin mayor novedad
2	2	NULL	6	30	Twitter	2025-08-27	Muy mala calidad, se rompió rápido
3	3	NULL	8	5	Instagram	2025-07-28	Gran relación calidad-precio
4	4	NULL	15	7	Twitter	2025-09-05	Pésima atención al cliente
5	5	31	10	7	Instagram	2025-09-04	No cumple con lo anunciado, insatisfecho
6	6	NULL	5	82	Facebook	2025-06-18	No cumple con lo anunciado, insatisfecho
7	7	36	17	10	Twitter	2025-07-20	No funciona como esperaba, decepcionado
8	8	NULL	17	8	Instagram	2025-08-25	Me encanta este producto, excelente calidad
9	9	21	10	74	Facebook	2025-07-09	Información suficiente, sin mayor novedad
10	10	NULL	10	30	Facebook	2025-08-28	Gran relación calidad-precio
11	11	NULL	10	74	Instagram	2025-07-01	Muy satisfecho con la compra, lo recomiendo
12	12	40	5	74	Facebook	2025-07-03	Satisface lo básico
13	13	NULL	2	74	Instagram	2025-07-02	Me encanta este producto, excelente calidad
14	14	NULL	9	82	Instagram	2025-06-24	Entrega correcta, sin comentarios adicionales
15	15	35	1	94	Facebook	2025-08-13	Producto llegó rápido y funciona perfecto
16	16	5	13	45	Facebook	2025-07-22	No funciona como esperaba, decepcionado
17	17	22	16	5	Instagram	2025-08-04	Envío tardío y producto dañado
18	18	NULL	12	74	Instagram	2025-07-04	Producto llegó rápido y funciona perfecto
19	19	30	4	8	Twitter	2025-08-26	Calidad superior, muy contento
20	20	25	4	8	Twitter	2025-08-24	Entrega correcta, sin comentarios adicionales

Tabla RegistrosRechazados:



	IdRechazo	Entidad	ArchivoOrigen	NumFila	IdOrigen	Motivo	DatoOriginal	FechaRechazo
1	1	Encuestas	surveys_part1.csv	2	1	Integridad referencial: el cliente y el producto n...	1 | 8537 | 366 | 2025-07-15 | El producto está bi...	2026-10-21 06:05:18
2	2	Encuestas	surveys_part1.csv	3	2	Integridad referencial: el cliente y el producto n...	2 | 2721 | 667 | 2024-12-07 | Ni malo ni excelent...	2026-10-21 06:05:18
3	3	Encuestas	surveys_part1.csv	4	3	Integridad referencial: el cliente y el producto n...	3 | 8424 | 953 | 2025-06-20 | Mala calidad, no lo...	2026-10-21 06:05:18
4	4	Encuestas	surveys_part1.csv	5	4	Integridad referencial: el cliente y el producto n...	4 | 9672 | 961 | 2025-08-17 | El producto está bi...	2026-10-21 06:05:18
5	5	Encuestas	surveys_part1.csv	6	5	Integridad referencial: el cliente y el producto n...	5 | 8018 | 607 | 2024-10-22 | El producto llegó e...	2026-10-21 06:05:18
6	6	Encuestas	surveys_part1.csv	7	6	Integridad referencial: el cliente no existe en el...	6 | 6119 | 89 | 2025-03-06 | El servicio fue rápid...	2026-10-21 06:05:18
7	7	Encuestas	surveys_part1.csv	8	7	Integridad referencial: el cliente y el producto n...	7 | 4890 | 478 | 2025-07-19 | El envío fue normal...	2026-10-21 06:05:18
8	8	Encuestas	surveys_part1.csv	9	8	Integridad referencial: el producto no existe en...	8 | 415 | 388 | 2025-02-06 | Me encanta, es just...	2026-10-21 06:05:18
9	9	Encuestas	surveys_part1.csv	10	9	Integridad referencial: el cliente y el producto n...	9 | 6110 | 970 | 2024-09-19 | El servicio fue rápi...	2026-10-21 06:05:18
10	10	Encuestas	surveys_part1.csv	11	10	Integridad referencial: el cliente no existe en el...	10 | 8693 | 48 | 2025-05-29 | Me encanta, es jus...	2026-10-21 06:05:18
11	11	Encuestas	surveys_part1.csv	12	11	Integridad referencial: el cliente no existe en el...	11 | 9269 | 74 | 2025-02-07 | El producto está bi...	2026-10-21 06:05:18
12	12	Encuestas	surveys_part1.csv	13	12	Integridad referencial: el cliente no existe en el...	12 | 3734 | 34 | 2025-05-30 | El producto está bi...	2026-10-21 06:05:18
13	13	Encuestas	surveys_part1.csv	14	13	Integridad referencial: el cliente y el producto n...	13 | 3629 | 930 | 2025-04-27 | El servicio fue lent...	2026-10-21 06:05:18
14	14	Encuestas	surveys_part1.csv	15	14	Integridad referencial: el cliente y el producto n...	14 | 1953 | 369 | 2025-06-23 | Ni malo ni excele...	2026-10-21 06:05:18
15	15	Encuestas	surveys_part1.csv	16	15	Integridad referencial: el producto no existe en...	15 | 253 | 385 | 2025-04-05 | El producto llegó d...	2026-10-21 06:05:18
16	16	Encuestas	surveys_part1.csv	17	16	Integridad referencial: el cliente y el producto n...	16 | 8697 | 750 | 2025-04-25 | El servicio fue ráp...	2026-10-21 06:05:18
17	17	Encuestas	surveys_part1.csv	18	17	Integridad referencial: el cliente y el producto n...	17 | 2756 | 339 | 2024-12-03 | El envío fue norm...	2026-10-21 06:05:18
18	18	Encuestas	surveys_part1.csv	19	18	Integridad referencial: el cliente y el producto n...	18 | 9132 | 390 | 2025-01-21 | El producto llegó ...	2026-10-21 06:05:18
19	19	Encuestas	surveys_part1.csv	20	19	Integridad referencial: el cliente y el producto n...	19 | 1370 | 393 | 2024-12-07 | Excelente calidad...	2026-10-21 06:05:18
20	20	Encuestas	surveys_part1.csv	21	20	Integridad referencial: el cliente y el producto n...	20 | 6506 | 271 | 2025-01-15 | Excelente calidad...	2026-10-21 06:05:18

4. **Al menos cinco consultas SQL que demuestren que la información fue cargada correctamente y mantiene la integridad referencial.**

```sql
-- ------------------------------------------------------------
-- CONSULTA 1: Cantidad de registros cargados en cada tabla
-- Esperado: Clientes 500, Productos 200, FuenteDatos 100,
--           Encuestas 6, ResenasWeb 200, ComentariosSociales 200
-- ------------------------------------------------------------
SELECT 'Clientes' AS Tabla, COUNT(*) AS Registros FROM dbo.Clientes
UNION ALL SELECT 'Productos', COUNT(*) FROM dbo.Productos
UNION ALL SELECT 'FuenteDatos', COUNT(*) FROM dbo.FuenteDatos
UNION ALL SELECT 'Encuestas', COUNT(*) FROM dbo.Encuestas
UNION ALL SELECT 'ResenasWeb', COUNT(*) FROM dbo.ResenasWeb
UNION ALL SELECT 'ComentariosSociales', COUNT(*) FROM dbo.ComentariosSociales;
GO
```

142 %

Results | Messages

	Tabla	Registros
1	Clientes	500
2	Productos	200
3	FuenteDatos	100
4	Encuestas	6
5	ResenasWeb	200
6	ComentariosSociales	200

```sql
-- ------------------------------------------------------------
-- CONSULTA 2: Integridad referencial - registros huérfanos
-- Busca opiniones cuyo cliente, producto o fuente no existe.
-- Esperado: 0 en las 9 filas
-- ------------------------------------------------------------
SELECT 'Encuestas sin cliente' AS Comprobacion, COUNT(*) AS Huerfanos
FROM dbo.Encuestas e LEFT JOIN dbo.Clientes c ON c.IdCliente = e.IdCliente
WHERE c.IdCliente IS NULL
UNION ALL
SELECT 'Encuestas sin producto', COUNT(*)
FROM dbo.Encuestas e LEFT JOIN dbo.Productos p ON p.IdProducto = e.IdProducto
WHERE p.IdProducto IS NULL
UNION ALL
SELECT 'Encuestas sin fuente', COUNT(*)
FROM dbo.Encuestas e LEFT JOIN dbo.FuenteDatos f ON f.IdFuente = e.IdFuente
WHERE f.IdFuente IS NULL
UNION ALL
SELECT 'Reseñas con cliente inexistente', COUNT(*)
FROM dbo.ResenasWeb r LEFT JOIN dbo.Clientes c ON c.IdCliente = r.IdCliente
WHERE r.IdCliente IS NOT NULL AND c.IdCliente IS NULL
UNION ALL
SELECT 'Reseñas sin producto', COUNT(*)
```

142 %

Results | Messages

	Comprobacion	Huerfanos
1	Encuestas sin cliente	0
2	Encuestas sin producto	0
3	Encuestas sin fuente	0
4	Reseñas con cliente inexistente	0
5	Reseñas sin producto	0
6	Reseñas sin fuente	0
7	Comentarios con cliente inexistente	0
8	Comentarios sin producto	0
9	Comentarios sin fuente	0

```sql
-- ------------------------------------------------------------
-- CONSULTA 3: Registros duplicados
-- Correos repetidos, códigos de fuente repetidos y opiniones
-- repetidas (mismo cliente, producto, fecha y comentario).
-- Esperado: 0 en las 5 filas (no deben salir duplicados)
-- ------------------------------------------------------------
SELECT 'Correos repetidos en Clientes' AS Comprobacion, COUNT(*) AS Duplicados
FROM (SELECT Email FROM dbo.Clientes GROUP BY Email HAVING COUNT(*) > 1) x
UNION ALL
SELECT 'Códigos de fuente repetidos', COUNT(*)
FROM (SELECT CodigoFuente FROM dbo.FuenteDatos GROUP BY CodigoFuente HAVING COUNT(*) > 1) x
UNION ALL
SELECT 'Encuestas repetidas', COUNT(*)
FROM (SELECT IdCliente, IdProducto, Fecha, Comentario FROM dbo.Encuestas
      GROUP BY IdCliente, IdProducto, Fecha, Comentario HAVING COUNT(*) > 1) x
UNION ALL
SELECT 'Reseñas repetidas', COUNT(*)
FROM (SELECT IdCliente, IdProducto, Fecha, Comentario FROM dbo.ResenasWeb
      GROUP BY IdCliente, IdProducto, Fecha, Comentario HAVING COUNT(*) > 1) x
UNION ALL
SELECT 'Comentarios sociales repetidos', COUNT(*)
FROM (SELECT IdCliente, IdProducto, Plataforma, Fecha, Comentario FROM dbo.ComentariosSociales
      GROUP BY IdCliente, IdProducto, Plataforma, Fecha, Comentario HAVING COUNT(*) > 1) x;
GO
```

142 %

Results | Messages

	Comprobacion	Huerfanos
1	Encuestas sin cliente	0
2	Encuestas sin producto	0
3	Encuestas sin fuente	0
4	Reseñas con cliente inexistente	0
5	Reseñas sin producto	0
6	Reseñas sin fuente	0
7	Comentarios con cliente inexistente	0
8	Comentarios sin producto	0
9	Comentarios sin fuente	0

```sql
-- CONSULTA 4: Cuadre del proceso: procesados = cargados + rechazados
-- Compara lo que entró a staging con lo que quedó en la base
-- transaccional y con lo rechazado.
-- Esperado: la columna Cuadra = 'SI' en las 6 filas
-- ------------------------------------------------------------
SELECT
    r.Entidad,
    r.EnStaging AS Procesados,
    r.EnTransaccional AS Cargados,
    r.Rechazados,
    CASE WHEN r.EnStaging = r.EnTransaccional + r.Rechazados THEN 'SI' ELSE 'NO' END AS Cuadra
FROM
(
    SELECT 'Clientes' AS Entidad,
           (SELECT COUNT(*) FROM stg.Clientes) AS EnStaging,
           (SELECT COUNT(*) FROM dbo.Clientes) AS EnTransaccional,
           (SELECT COUNT(*) FROM stg.RegistrosRechazados WHERE Entidad = 'Clientes') AS Rechazados
    UNION ALL
    SELECT 'Productos',
           (SELECT COUNT(*) FROM stg.Productos),
           (SELECT COUNT(*) FROM dbo.Productos),
           (SELECT COUNT(*) FROM stg.RegistrosRechazados WHERE Entidad = 'Productos')
    UNION ALL
    SELECT 'FuenteDatos',
           (SELECT COUNT(*) FROM stg.FuenteDatos),
```

142 %

Results | Messages

	Entidad	Procesados	Cargados	Rechazados	Cuadra
1	Clientes	500	500	0	SI
2	Productos	200	200	0	SI
3	FuenteDatos	100	100	0	SI
4	Encuestas	500	6	494	SI
5	ResenasWeb	200	200	0	SI
6	ComentariosSociales	200	200	0	SI

```sql
-- ------------------------------------------------------------
-- CONSULTA 9: Prueba de que la base protege la integridad
-- Este INSERT DEBE FALLAR con un error de FOREIGN KEY
-- (el cliente 99999 no existe). Se ejecuta dentro de una
-- transacción que se deshace, por lo que no deja datos.
-- Esperado: Error 547 "The INSERT statement conflicted with
--           the FOREIGN KEY constraint ..."
-- ------------------------------------------------------------
BEGIN TRANSACTION;
    INSERT INTO dbo.ResenasWeb (IdCliente, IdProducto, IdFuente, Fecha, Comentario, Rating)
    VALUES (99999, 1, 1, '2025-01-01', N'Prueba de integridad', 3);
ROLLBACK TRANSACTION;
GO

-- ------------------------------------------------------------
-- CONSULTA 10: Vistas y procedimientos almacenados
```

```
Messages
Msg 547, Level 16, State 0, Line 218
The INSERT statement conflicted with the FOREIGN KEY constraint "FK_ResenasWeb_Clientes". The conflict occurred in database "AnalisisOpinionesTransaccional", table "dbo.Clientes", column 'IdCliente'.
The statement has been terminated.

Completion time: 2026-10-21T21:32:41.3871297-04:00
```

12. Cómo ejecutar el proyecto

- Abrir sql/script_base_datos.sql en SSMS y ejecutarlo completo (F5).
- Instalar la dependencia con pip install -r requirements.txt.
- Abrir el archivo config.py, que está en la carpeta principal del proyecto, junto a main.py. En la sección “Conexión a SQL Server”, escribir en las comillas vacías de DB_SERVER el nombre de su servidor de SQL Server (el que aparece en SSMS) para que pueda funcionar sin problemas.
- Ejecutar python main.py.
- Correr en SSMS las consultas de sql/consultas_validacion.sql, una por una.
- (Opcional) Correr las pruebas automáticas con python -m unittest discover -s tests -v. Debe terminar con “Ran 30 tests” y “OK”.

13. Conclusión

El proceso carga correctamente los seis archivos en la base transaccional: 1,700 registros procesados, 1,206 insertados y 494 rechazados con su motivo. Las consultas de validación confirman que no hay registros huérfanos ni duplicados y que las claves foráneas se cumplen. El principal punto a revisar son las encuestas, que en su mayoría referencian clientes y productos que no existen en los catálogos entregados.

Anexo. Estructura de la entrega

```
ETL_Opiniones/
├── main.py
├── config.py
├── requirements.txt
├── .gitignore
├── data/                (6 CSV)
├── sql/                 (script_base_datos.sql, consultas_validacion.sql)
├── etl/                 (módulos del proceso)
├── tests/               (30 pruebas de validación)
├── logs/                (registros que genera el programa)
└── evidencias/
    ├── logs/            (log de la ejecución final)
    ├── capturas/        (capturas de pantalla)
    └── informe/         (informe)
```